

Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa
Programa de Pós-Graduação em Administração Pública
Mestrado Profissional

TÉCNICAS DE AVALIAÇÃO DE SISTEMAS RAG
aplicação empírica a discursos legislativos do Senado Federal

FABRICIO FERNANDES SANTANA

Brasília/DF
Maio/2026

FABRICIO FERNANDES SANTANA

TÉCNICAS DE AVALIAÇÃO DE SISTEMAS RAG
aplicação empírica a discursos legislativos do Senado Federal

Pré-projeto de dissertação apresentado como requisito final para avaliação na disciplina de Projeto de Pesquisa, do Mestrado Profissional em Administração Pública, do Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa (IDP), ministrada pelos Profs. Drs. Hélio Bomfim de Macêdo Filho e Marcelo Rodrigo de Souza Pita.

Brasília/DF
Maio/2026

FABRICIO FERNANDES SANTANA

TÉCNICAS DE AVALIAÇÃO DE SISTEMAS RAG
aplicação empírica a discursos legislativos do Senado Federal

BANCA EXAMINADORA:

Prof. Dr. Hélio Bomfim de Macêdo Filho
Projeto de Pesquisa

Prof. Dr. Marcelo Rodrigo de Souza Pita
Projeto de Pesquisa

Sumário

1	Introdução	1
1.1	Contextualização temática	1
1.2	Apresentação da problemática e da pergunta de pesquisa	2
1.3	Enunciação dos objetivos	3
1.3.1	Geral	3
1.3.2	Específicos	3
2	Referencial teórico	4
2.1	Inteligência artificial generativa, RAG e recuperação de informação	4
2.2	Informação legislativa, transparência e acervos parlamentares	5
2.3	Avaliação de sistemas RAG e governança pública de IA	5
2.4	Lacuna de pesquisa	6
3	Hipótese(s) do estudo	7
4	Metodologia	9
4.1	Natureza e abordagem da pesquisa	9
4.2	Fundamentação empírica: dados e técnicas de coleta	10
4.3	Técnicas de análise dos dados e matriz de opções metodológicas	11
5	Cronograma da pesquisa	14
6	Referências	16

1. INTRODUÇÃO

1.1. Contextualização temática

No campo da inteligência artificial generativa, grandes modelos de linguagem (*large language models* – LLMs) são modelos capazes de produzir texto em linguagem natural a partir de padrões aprendidos em grandes volumes de dados (MINAEE et al., 2024). A abordagem *retrieval-augmented generation* (RAG) combina esses modelos generativos com mecanismos de recuperação de informação, de modo que a resposta seja produzida com apoio em documentos recuperados de uma base externa, e não apenas a partir do conhecimento paramétrico do modelo (LEWIS et al., 2020; GAO et al., 2023).

Ao condicionar a geração textual a evidências recuperadas, o RAG tem sido apresentado na literatura como uma estratégia relevante para aproximar LLMs de bases documentais controladas (LEWIS et al., 2020; GAO et al., 2023). Essa arquitetura pode favorecer atualização em relação à base consultada, rastreabilidade e controle documental, especialmente quando comparada ao uso isolado de LLMs em tarefas de resposta a perguntas (GAO et al., 2023; GUPTA et al., 2024).

A literatura trata a avaliação de sistemas RAG como um problema multidimensional (SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024). Isso ocorre porque a qualidade de uma resposta depende tanto de componentes distintos e interdependentes do *pipeline* quanto dos critérios usados para avaliá-la. Entre esses componentes estão preparação dos dados, segmentação textual, qualidade dos metadados, modelo de *embedding*, estratégia de recuperação, seleção ou reranqueamento de contexto, desenho do *prompt*, modelo gerador e critérios de pós-processamento (GAO et al., 2023; GUPTA et al., 2024).

Nesse sentido, uma resposta linguisticamente adequada pode estar apoiada em evidências frágeis; uma recuperação relevante pode ser mal utilizada pela geração; e uma avaliação automatizada pode superestimar respostas plausíveis, mas insuficientemente fundamentadas. Avaliar RAG exige, portanto, distinguir recuperação documental, geração textual, fidelidade ao contexto, verificabilidade das fontes, robustez por tipo de pergunta, julgamento humano e avaliação automatizada (SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024).

Esse desafio avaliativo ganha relevância adicional em contextos públicos. A administração pública contemporânea depende de acervos digitais extensos para documentar decisões, preservar memória institucional, prestar contas à sociedade e apoiar processos de formulação, acompanhamento e avaliação de políticas públicas. Nesses ambientes, respostas produzidas por sistemas generativos não podem ser avaliadas apenas por fluência ou utilidade aparente: precisam ser verificáveis, rastreáveis, proporcionais às evidências recuperadas e compatíveis com requisitos de transparência, responsabilização e governança (WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023; ALMEIDA; SANTOS

JÚNIOR, 2025; INTER-PARLIAMENTARY UNION, 2024).

No Poder Legislativo, esse problema assume contornos específicos. Discursos parlamentares, debates, proposições, pareceres e demais documentos públicos registram posições políticas, justificativas, argumentos técnicos e trajetórias institucionais que interessam a parlamentares, equipes técnicas, pesquisadores, jornalistas, organizações da sociedade civil e cidadãos (BANDEIRA; BERNARDES, 2016; GEUNIS, 2023). Embora a publicidade desses documentos seja condição necessária para a transparência, ela não garante, por si só, acesso substantivo à informação. Grandes acervos legislativos são marcados por volume elevado, diversidade temática, dispersão temporal, variação terminológica e dependência de metadados, o que desafia mecanismos tradicionais de busca e também tensiona sistemas RAG (SKUBIC; FIŠER, 2024; MARTELLOTE VIOLA et al., 2025).

O tema desta pesquisa, portanto, é o estudo de técnicas de avaliação de sistemas RAG e sua aplicação a um caso empírico de interesse público. A dissertação tomará como campo de aplicação um sistema RAG voltado à consulta a discursos da 56^a Legislatura do Senado Federal. Esse caso permite examinar, em um acervo documental real, como diferentes técnicas de avaliação capturam dimensões complementares da qualidade, tais como recuperação de evidências, fidelidade ao contexto, verificabilidade das fontes, utilidade da resposta, calibração da incerteza e limites de uso institucional.

1.2. Apresentação da problemática e da pergunta de pesquisa

O problema de pesquisa decorre da dificuldade de organizar e aplicar, de forma articulada, técnicas de avaliação de sistemas RAG. Essa dificuldade será examinada empiricamente a partir de um sistema RAG aplicado a discursos da 56^a Legislatura do Senado Federal, tomado como caso concreto para analisar recuperação documental, geração de respostas e verificabilidade das fontes.

Órgãos públicos acumulam acervos de alto valor institucional, mas a adoção de sistemas generativos para explorá-los exige critérios capazes de indicar quando uma resposta é útil, verificável e suficientemente ancorada nas fontes. A literatura sobre RAG já propõe métricas, benchmarks, rubricas, avaliações humanas e estratégias de LLM como juiz, mas ainda há desafios para organizar essas técnicas em protocolos aplicáveis a domínios institucionais específicos, nos quais recuperação, geração e governança precisam ser analisadas em conjunto (GAO et al., 2023; ES et al., 2023; SAAD-FALCON et al., 2024; LIU, S. et al., 2025).

Em contextos jurídico-legislativos, estudos já exploram RAG, LLMs e recuperação semântica em legislação, parlamentos e política, incluindo *fact-checking* político, redação legislativa, consulta a legislação extensa, interfaces conversacionais e sistemas híbridos com grafos de conhecimento (KHALIQ et al., 2024; CHOUHAN; GERTZ, 2024; GARRISON et al., 2024; ROGIERS et al., 2024; MATOSHI et al., 2025; COLOMBO et al., 2025;

MOSBACH et al., 2025). No contexto brasileiro, há estudos sobre discursos parlamentares e organização do conhecimento legislativo (BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025). Ainda assim, permanece espaço para uma investigação que tome a avaliação de RAG como objeto central e use o acervo legislativo brasileiro como caso de aplicação de técnicas avaliativas.

Diante disso, formula-se a seguinte pergunta de pesquisa: **como técnicas de avaliação de sistemas RAG podem ser organizadas e aplicadas à análise de recuperação, geração e verificabilidade em discursos da 56^a Legislatura do Senado Federal?**

A justificativa prática da pesquisa está na necessidade de avaliar, com critérios explícitos, sistemas generativos aplicados a acervos documentais de interesse público. Sistemas RAG podem ampliar a mediação entre usuários e documentos legislativos, mas seu uso institucional exige critérios capazes de indicar quando a resposta está adequadamente ancorada em fontes, quando extrapola o contexto recuperado e quando deve explicitar incerteza ou insuficiência documental. Assim, a contribuição esperada não está em defender a adoção automática de chatbots generativos, mas em oferecer uma forma mais criteriosa de avaliá-los antes de qualquer uso ampliado.

No plano científico, a pesquisa se justifica porque a avaliação de RAG ainda é um campo em consolidação, especialmente quando transposta de benchmarks genéricos para domínios públicos específicos. Métricas de recuperação, rubricas de geração, avaliação humana e LLM como juiz medem dimensões complementares, mas nenhuma delas, isoladamente, resolve o problema de verificar qualidade, rastreabilidade e condições de uso institucional. Ao tratar o sistema RAG como artefato sociotécnico, a dissertação pretende organizar essas técnicas em um protocolo aplicado a um corpus legislativo brasileiro, distinguindo dimensões que, na prática, tendem a aparecer sobrepostas: recuperação documental, geração textual, julgamento automatizado, validação humana, verificabilidade e condições de governança.

1.3. Enunciação dos objetivos

1.3.1. GERAL

Sistematizar técnicas de avaliação de sistemas RAG e aplicá-las a um caso empírico de consulta a discursos da 56^a Legislatura do Senado Federal, com foco na recuperação documental, na geração de respostas e na verificabilidade das fontes.

1.3.2. ESPECÍFICOS

1. sistematizar a literatura sobre técnicas de avaliação de RAG, incluindo métricas de recuperação, avaliação de geração, benchmarks, rubricas, avaliação humana e LLM como juiz;

2. selecionar, a partir da sistematização da literatura, técnicas de avaliação de RAG a serem aplicadas ao caso empírico, contemplando recuperação documental, geração de respostas, verificabilidade, robustez e governança;
3. caracterizar o acervo de discursos parlamentares da 56^a Legislatura do Senado Federal como caso empírico da pesquisa;
4. construir uma bateria de perguntas de teste, com categorias, respostas esperadas e evidências documentais de referência;
5. aplicar técnicas de avaliação, rubrica de avaliação humana e avaliação auxiliar por LLM como juiz ao caso empírico da pesquisa;
6. analisar a complementaridade, os limites e as condições de uso das técnicas avaliativas quando aplicadas a um acervo legislativo real, incluindo as condições de governança necessárias à interpretação institucional dos resultados.

2. REFERENCIAL TEÓRICO

Esta seção organiza os fundamentos teóricos que sustentam a pergunta de pesquisa e as escolhas metodológicas do projeto. O argumento está estruturado em três eixos complementares: a relação entre inteligência artificial generativa, RAG e recuperação de informação; as especificidades da informação legislativa como acervo público; e os critérios de avaliação e governança aplicáveis a sistemas RAG em domínios institucionais.

2.1. Inteligência artificial generativa, RAG e recuperação de informação

Os grandes modelos de linguagem ampliaram a capacidade de interação com sistemas computacionais por meio de linguagem natural, viabilizando tarefas de sumarização, classificação, geração de texto, resposta a perguntas e apoio à análise documental (MINAEE et al., 2024). Sua arquitetura se apoia em avanços associados aos *transformers*, que se tornaram base técnica para modelos generativos contemporâneos (VASWANI et al., 2017). Apesar dessas capacidades, LLMs não são mecanismos de recuperação documental por definição: suas respostas podem refletir padrões aprendidos no treinamento, inferências probabilísticas e lacunas de atualização, sem indicar de forma confiável quais documentos sustentam cada afirmação (ANH-HOANG et al., 2025).

O RAG surge como uma estratégia para aproximar geração textual e recuperação de informação. Na formulação clássica, a arquitetura combina um mecanismo de recuperação sobre base externa com um modelo generativo que produz a resposta a partir do contexto recuperado (LEWIS et al., 2020). Revisões recentes classificam essas arquiteturas em configurações ingênuas, avançadas e modulares, destacando que o desempenho depende de todo o pipeline, não apenas do modelo final de geração (GAO et al., 2023,

2024). Componentes como extração documental, segmentação em *chunks*, enriquecimento por metadados, geração de *embeddings*, recuperação vetorial, reranking, seleção de contexto e *prompting* orientado a evidências influenciam diretamente a qualidade das respostas (GUPTA et al., 2024; NIE et al., 2024).

Essa literatura é central para o projeto porque desloca a análise de uma discussão genérica sobre “uso de IA” para um problema metodológico delimitado: a avaliação das condições em que uma arquitetura RAG recupera evidências pertinentes, gera respostas verificáveis e reconhece limites de escopo. Essa delimitação exige distinguir, no desenho da pesquisa, a recuperação documental, a geração textual e o julgamento das respostas.

2.2. Informação legislativa, transparência e acervos parlamentares

O acesso à informação pública é dimensão central da administração democrática, mas a disponibilidade formal de documentos não elimina barreiras de compreensão, localização e uso qualificado. No domínio legislativo, discursos, debates e registros parlamentares são fontes relevantes para reconstruir posicionamentos, agendas, conflitos, justificativas e memória institucional (SKUBIC; FIŠER, 2024). Ao mesmo tempo, esses acervos podem ser difíceis de explorar por mecanismos convencionais de busca, sobretudo quando o usuário não conhece previamente a terminologia exata, os atores envolvidos ou a organização dos registros (BANDEIRA; BERNARDES, 2016; GEUNIS, 2023).

No caso brasileiro, estudos recentes da Consultoria Legislativa do Senado mostram que os pronunciamentos em plenário formam um corpus extenso, dinâmico e analiticamente relevante, com variações de volume, extensão, interatividade e complexidade textual ao longo do tempo (BLANCO, 2025, 2026). Em paralelo, pesquisas sobre organização do conhecimento legislativo indicam que o uso de inteligência artificial nesse domínio precisa considerar estrutura informacional, explicabilidade, mediação documental e confiabilidade dos resultados (MARTELLOTE VIOLA et al., 2025).

Assim, a informação legislativa não deve ser tratada apenas como massa textual a ser processada. Trata-se de um recurso institucional, marcado por regras de produção, metadados, autoria, temporalidade, retificações, usos políticos e requisitos de accountability (BANDEIRA; BERNARDES, 2016; MARTELLOTE VIOLA et al., 2025). Essa característica reforça a necessidade de combinar inovação técnica com critérios de governança pública.

2.3. Avaliação de sistemas RAG e governança pública de IA

A avaliação de sistemas RAG apresenta desafios próprios porque uma resposta final aparentemente correta pode ocultar recuperação deficiente, uso inadequado das fontes, extrapolação além do contexto ou julgamento automatizado permissivo. Por isso, a literatura recomenda distinguir métricas de recuperação, métricas de geração, avaliação

humana, avaliação automatizada por LLM e análise qualitativa de erros (SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024). Benchmarks recentes também apontam a importância de testar diferentes famílias de perguntas, como questões factuais, comparativas, temporais, multietapas, numéricas e não respondíveis (ZHU et al., 2025).

Entre essas técnicas, o uso de LLM como juiz merece atenção específica neste projeto porque permite avaliar respostas geradas com base em rubricas explícitas (LIU, Y. et al., 2023; LIU, S. et al., 2025). Essa abordagem pode ajudar a escalar avaliações, mas não elimina a necessidade de validação humana, pois o julgamento automatizado pode variar conforme modelo, rubrica, formato de entrada e complexidade da tarefa. Em domínios públicos, esse ponto é decisivo: uma avaliação automatizada não deve ser confundida com certificação de qualidade institucional.

No campo da governança pública de IA, diretrizes e estudos enfatizam transparência, finalidade pública, gestão de riscos, supervisão humana, monitoramento e responsabilização (INTER-PARLIAMENTARY UNION, 2024; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023; ALMEIDA; SANTOS JÚNIOR, 2025). Para sistemas RAG aplicados a acervos legislativos, tais princípios sugerem que a solução deve ser avaliada não apenas por sua fluência textual, mas também por sua capacidade de preservar fontes, explicitar incerteza, evitar atribuições indevidas, registrar configurações, permitir auditoria e delimitar usos aceitáveis.

2.4. Lacuna de pesquisa

A literatura existente oferece bases técnicas robustas para compreender RAG e avaliação de LLMs, bem como estudos relevantes sobre informação legislativa e parlamentos. Entretanto, os trabalhos mais próximos distribuem-se em frentes ainda pouco integradas. Estudos sobre RAG enfatizam arquitetura, recuperação, geração e avaliação automatizada, mas frequentemente tratam domínios genéricos ou jurídicos mais amplos (GAO et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024). Pesquisas sobre parlamentos e informação legislativa discutem acesso, transparência, discurso parlamentar e organização do conhecimento, mas nem sempre implementam ou avaliam sistemas conversacionais baseados em RAG (SKUBIC; FIŠER, 2024; BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025). Aplicações recentes em legislação e política, por sua vez, exploram fact-checking, redação legislativa, consulta a textos normativos, interfaces conversacionais e arquiteturas híbridas, mas diferem quanto a corpus, língua, jurisdição, tarefa e desenho de avaliação (KHALIQ et al., 2024; CHOUHAN; GERTZ, 2024; GARRISON et al., 2024; ROGIERS et al., 2024; MATOSHI et al., 2025; COLOMBO et al., 2025; MOSBACH et al., 2025).

Desse modo, a lacuna refere-se à escassez de estudos empíricos que combinem, no mesmo desenho de pesquisa e no contexto brasileiro, um acervo parlamentar real,

um pipeline RAG reproduzível, avaliação formal da recuperação, avaliação humana das respostas e discussão institucional sobre condições de uso. No caso desta pesquisa, essa lacuna será examinada em discursos da 56^a Legislatura do Senado Federal, com atenção simultânea à recuperação, à geração e à verificabilidade das fontes. O foco do estudo recai sobre as condições em que a recuperação documental, a geração textual e a governança do artefato podem sustentar uma consulta legislativa verificável.

Essa lacuna é especialmente relevante para programas profissionais em administração pública, pois envolve simultaneamente desenho de artefato, avaliação empírica e implicações institucionais. A dissertação proposta busca contribuir para esse espaço ao desenvolver uma investigação com critérios metodológicos explícitos sobre avaliação e governança de RAG em acervos legislativos.

3. HIPÓTESE(S) DO ESTUDO

A pesquisa não será tratada como teste causal clássico entre uma variável independente e uma variável dependente única. Por se tratar de investigação aplicada, multimétodos e orientada à avaliação de um artefato sociotécnico, as hipóteses assumem a forma de proposições verificáveis, isto é, respostas provisórias ao problema de pesquisa que poderão ser confirmadas, rejeitadas ou qualificadas pelas evidências empíricas. Essa opção é compatível com a *Design Science Research*, na qual a construção e a avaliação de artefatos constituem parte do processo de produção de conhecimento (HEVNER et al., 2004; PEFFERS et al., 2007).

As proposições preliminares são as seguintes:

- P1. A pertinência das evidências recuperadas é condição necessária, mas não suficiente, para a verificabilidade das respostas.** A proposição será examinada pela análise conjunta de dois tipos de falha: falhas de verificabilidade decorrentes de recuperação impertinente e falhas que ocorrem mesmo com recuperação pertinente, quando a geração não associa explicitamente afirmações a fontes ou extrapola o contexto recuperado. A proposição será considerada corroborada se os dois tipos de falha forem observados de forma independente; será rejeitada ou qualificada se as falhas de verificabilidade coincidirem integralmente com falhas de recuperação. O baseline de LLM sem recuperação documental será usado apenas como referência auxiliar, pois o foco da proposição recai sobre a relação entre evidências recuperadas, fontes citadas e verificabilidade das respostas.
- P2. O desempenho do sistema tende a ser inferior em perguntas que exigem integração de múltiplas evidências, raciocínio em etapas ou reconhecimento de informação ausente, em comparação com perguntas factuais, temáticas e delimitadas por autor.** A proposição será examinada por meio de uma bateria de

perguntas organizada por categorias operacionais, com comparação de desempenho agregado e análise de erro entre grupos de categorias. Será considerada corroborada se houver diferença consistente de desempenho na direção esperada; será qualificada ou rejeitada se o desempenho se mostrar homogêneo ou inverso. Essa expectativa direcional deriva de benchmarks e estudos de avaliação de RAG, que mostram variação de desempenho conforme complexidade da pergunta, necessidade de integração de evidências e presença de questões não respondíveis (SAAD-FALCON et al., 2024; ES et al., 2023; ZHU et al., 2025; PIPITONE; HOUIR ALAMI, 2024).

P3. A avaliação por LLM como juiz é útil, mas insuficiente como critério único. A proposição será examinada pela comparação entre julgamentos automatizados e avaliação humana independente. A avaliação por LLM pode contribuir para triagem e análise em escala, mas pode divergir da avaliação humana em casos de escopo documental ambíguo, atribuição de autoria, resposta formalmente plausível ou evidência insuficiente. Essa proposição se fundamenta na literatura sobre avaliação automatizada de linguagem natural e sobre uso de LLMs como avaliadores, que aponta sensibilidade a rubricas, modelos e formato de entrada (LIU, Y. et al., 2023; LIU, S. et al., 2025).

P4. O desempenho técnico, isoladamente, é insuficiente para sustentar juízo sobre as condições de uso institucional do sistema; esse juízo depende também de requisitos verificáveis de governança. A proposição será examinada pela identificação, na análise qualitativa de erros e casos críticos, de situações em que respostas tecnicamente adequadas ainda dependeriam de salvaguardas institucionais, como curadoria da base, atualização controlada, registro de versões, supervisão humana, rastreabilidade das fontes e mecanismos de auditoria, para uso responsável. Essa proposição deriva das diretrizes e estudos sobre governança de IA no setor público e em parlamentos, que enfatizam transparência, responsabilização e monitoramento contínuo (INTER-PARLIAMENTARY UNION, 2024; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023; ALMEIDA; SANTOS JÚNIOR, 2025).

Essas proposições serão operacionalizadas por critérios observáveis. A verificabilidade será examinada pela presença, pertinência e correção das fontes citadas, bem como pela possibilidade de associar afirmações da resposta a trechos recuperados. A variação por tipo de pergunta será avaliada por desempenho agregado e análise de erro em cada categoria da bateria. As divergências entre avaliação humana e LLM como juiz serão estimadas por diferenças de pontuação, taxas de falso positivo e falso negativo de qualidade e análise qualitativa de casos críticos. As condições de uso institucional serão discutidas a partir dos requisitos de governança identificados no protocolo, como curadoria, atualização, versionamento, supervisão humana e auditabilidade. O papel dessas proposições é

orientar a seleção de dados, métricas, baselines, rubricas, categorias de pergunta e critérios de interpretação dos resultados.

4. METODOLOGIA

4.1. Natureza e abordagem da pesquisa

A pesquisa proposta possui natureza aplicada, exploratória e descritiva. É aplicada porque se volta a um problema concreto da administração pública: a consulta qualificada, verificável e passível de governança a acervos legislativos extensos. É exploratória porque investiga possibilidades, limites e condições de uso de sistemas RAG em contexto institucional específico, em um campo ainda em consolidação. É descritiva porque buscará caracterizar o desempenho do sistema por tipos de pergunta, configurações de recuperação, categorias de erro e critérios de qualidade. Essa classificação segue a orientação metodológica de explicitar a natureza da pesquisa em função do problema investigado e do tipo de evidência necessário para respondê-lo (GIL, 2022).

Quanto ao método de abordagem, a pesquisa terá orientação predominantemente hipotético-dedutiva, com componente indutivo na análise de erros e na formulação de recomendações. Parte-se de proposições derivadas da literatura sobre RAG, avaliação de sistemas generativos, informação legislativa e governança pública de IA; em seguida, essas proposições serão confrontadas com evidências empíricas obtidas no caso estudado. Ao mesmo tempo, a análise qualitativa dos casos críticos poderá revelar padrões não previstos inicialmente, que serão usados para refinar recomendações metodológicas e institucionais. Essa combinação é adequada porque o projeto confronta respostas provisórias ao problema de pesquisa com evidências observáveis, mas também admite aprendizado a partir da observação sistemática dos resultados (LAKATOS; MARCONI, 2021). Essa orientação não implica teste causal clássico entre variáveis isoladas; as proposições serão examinadas por critérios de avaliação aplicados ao artefato e ao corpus estudado.

A abordagem será multimétodos. A dimensão quantitativa aparecerá na avaliação de recuperação, na comparação entre configurações ou baselines, nas métricas por categoria de pergunta, na análise de estabilidade e na comparação entre julgamentos. A dimensão qualitativa estará presente na revisão bibliográfica, na análise de erros, na interpretação de divergências entre avaliadores humanos e LLM como juiz, na discussão de governança e na leitura contextualizada de respostas representativas. O uso combinado de estratégias quantitativas e qualitativas é pertinente porque o fenômeno investigado envolve tanto desempenho mensurável quanto adequação institucional, qualidade argumentativa, interpretação documental e riscos de uso (CRESWELL; PLANO CLARK, 2018).

Como delineamento, a dissertação combinará pesquisa bibliográfica, pesquisa documental, estudo de caso aplicado e avaliação controlada do artefato. A pesquisa bibliográfica sistematizará literatura sobre RAG, avaliação de sistemas generativos, recuperação

de informação, informação legislativa e governança de IA. A pesquisa documental trabalhará com discursos parlamentares e metadados legislativos públicos. O estudo de caso concentrará a análise em um sistema RAG aplicado aos discursos da 56^a Legislatura do Senado Federal. A avaliação controlada será usada para comparar recuperação, geração e julgamento das respostas sob critérios previamente definidos, sem pretensão de generalizar os resultados para todas as arquiteturas RAG. O enquadramento geral dialoga com a *Design Science Research*, pois a dissertação avaliará um artefato computacional construído para enfrentar um problema relevante de informação pública (HEVNER et al., 2004; PEFFERS et al., 2007).

4.2. Fundamentação empírica: dados e técnicas de coleta

O corpus empírico principal será composto por discursos parlamentares da 56^a Legislatura do Senado Federal, derivados de registros públicos previamente organizados em dataset aberto. A pesquisa utilizará dados secundários, de natureza pública e documental, sem coleta direta de informações junto a participantes humanos para construção do corpus. Serão registrados, quando disponíveis, metadados como data, autor, partido, unidade federativa, tipo de uso da palavra, resumo, indexação e URL do discurso original. A unidade empírica principal será o sistema RAG construído sobre esse corpus. As comparações com baseline de LLM sem recuperação documental, busca lexical ou variações controladas do protocolo terão função auxiliar: servirão para interpretar dimensões específicas da avaliação, sem representar amostra de todas as arquiteturas RAG existentes.

As técnicas de coleta serão organizadas em três frentes, conforme a distinção metodológica entre pesquisa de fontes, elaboração dos dados e registro de protocolos. A primeira frente será bibliográfica e técnico-normativa, com levantamento de artigos, surveys, benchmarks, relatórios institucionais e diretrizes sobre RAG, avaliação de LLMs, informação legislativa e governança de IA. A segunda frente será documental, com coleta, congelamento e registro de versão do corpus de discursos parlamentares e de seus metadados. A terceira frente será avaliativa, com coleta dos resultados produzidos pelo sistema RAG, pelos baselines auxiliares, pelos avaliadores humanos e pelos julgamentos automatizados por LLM como juiz.

A coleta e organização dos dados envolverão as seguintes etapas:

1. congelamento de uma versão do corpus e registro de manifesto de dados, versões e hashes;
2. preparação textual e segmentação dos documentos em unidades recuperáveis;
3. enriquecimento dos trechos com metadados legislativos;
4. ingestão em base vetorial e configuração do fluxo RAG;

5. construção de bateria ampliada de perguntas, balanceada por categorias;
6. elaboração de gold standard de recuperação, com documentos ou trechos esperados por pergunta;
7. geração de respostas pelo sistema RAG principal, por baselines auxiliares e por variações controladas do protocolo;
8. coleta de julgamentos humanos independentes e julgamentos auxiliares por LLM como juiz.

As categorias de perguntas deverão incluir, entre outras, questões factuais, foco em autor, desambiguação, evidência negativa, comparação entre autores, comparação temporal, pergunta numérica, síntese temática, pergunta multietapas, autoria cruzada, controle de escopo e estresse de recuperação. A escolha dessas categorias se fundamenta em três critérios. Primeiro, elas dialogam com famílias de tarefas recorrentes em benchmarks e avaliações de RAG, como perguntas factuais, integração de informações, comparação, raciocínio em múltiplas etapas, síntese e perguntas não respondíveis (ZHU et al., 2025; SAAD-FALCON et al., 2024; ES et al., 2023). Segundo, contemplam dimensões particularmente relevantes para domínios jurídicos e legislativos, nos quais a qualidade da resposta depende não apenas de fluência, mas também de recuperação da fonte pertinente, fidelidade ao contexto, precisão de autoria, evidência suficiente e abstinência diante de informação ausente ou ambígua (PIPITONE; HOUIR ALAMI, 2024; DAHL et al., 2024). Terceiro, incorporam riscos observáveis no próprio domínio empírico dos discursos parlamentares, como variação terminológica, dispersão temporal, multiplicidade de autores, presença de discursos sobre temas semelhantes e necessidade de distinguir consulta exploratória de afirmação documental verificável (BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025). Essa tipologia poderá ser ajustada após piloto metodológico.

4.3. Técnicas de análise dos dados e matriz de opções metodológicas

A análise dos dados será organizada em quatro camadas. A primeira avaliará a recuperação documental por meio de métricas de recuperação ranqueada consolidadas na literatura de recuperação de informação, como *Recall@k*, *Precision@k*, MRR e nDCG (MANNING et al., 2008), também empregadas em benchmarks contemporâneos de recuperação como o BEIR (THAKUR et al., 2021). Adicionalmente, poderá ser usado *Hit@k*, entendido como medida operacional de acerto no topo da lista, isto é, a presença de pelo menos uma evidência relevante entre os k primeiros resultados, conforme viabilidade do gold standard.

A segunda camada avaliará a geração das respostas por rubrica, considerando correte factua, aderência ao contexto recuperado, fidelidade às fontes, precisão de

autoria, calibração da incerteza, completude proporcional e ausência de alucinação. A terceira camada comparará avaliação humana e avaliação por LLM como juiz, observando concordâncias, divergências, falsos positivos de qualidade e falsos negativos. A quarta camada analisará qualitativamente erros e condições de uso institucional, relacionando os achados a requisitos de governança, transparência, supervisão humana e auditabilidade.

Essas camadas operacionalizam as proposições do estudo. A verificabilidade será examinada pela relação entre evidências recuperadas, fontes citadas e afirmações geradas. A variação por tipo de pergunta será analisada por desempenho agregado e padrões de erro em cada categoria da bateria. O alcance e os limites do LLM como juiz serão avaliados pela comparação com julgamentos humanos independentes. As condições de governança serão discutidas a partir dos resultados técnicos, dos casos críticos e dos requisitos institucionais identificados na literatura.

O protocolo mínimo da dissertação incluirá: o sistema RAG principal; um baseline de LLM sem recuperação documental; um baseline de busca lexical; uma avaliação da recuperação vetorial sem geração; uma bateria balanceada de perguntas com gold standard; avaliação humana independente de uma amostra de respostas; e avaliação auxiliar por LLM como juiz sobre a mesma amostra ou sobre conjunto ampliado. Como extensões desejáveis, condicionadas a tempo, custo e viabilidade técnica, poderão ser incluídos reranqueamento, variação de modelos de *embedding*, variação de modelo gerador, múltiplos modelos usados como juízes e estudos de ablação mais amplos. Ao separar mínimo obrigatório e extensões desejáveis, busca-se evitar que a validade da dissertação dependa de todos os experimentos possíveis.

A avaliação humana será organizada por rubrica explícita, aplicada de preferência por pelo menos dois avaliadores independentes com familiaridade mínima com documentação legislativa ou avaliação de sistemas de informação. Antes da anotação principal, será realizado piloto com amostra reduzida de perguntas para calibrar instruções, exemplos positivos, exemplos negativos e casos limítrofes. Sempre que viável, os avaliadores não terão acesso à identidade do sistema que gerou cada resposta. Divergências serão registradas e, quando necessário, adjudicadas por revisão conjunta ou por avaliador adicional. A concordância será descrita por percentual de acordo e, se o desenho final permitir, por medida apropriada de concordância interavaliadores, como Cohen's kappa ou Krippendorff's alpha. A interpretação dos resultados será cautelosa e proporcional ao desenho amostral, evitando apresentar médias agregadas como prova isolada de qualidade.

A seguir apresenta-se a matriz preliminar de opções metodológicas que a pesquisa empregará:

Tabela 1: Matriz preliminar de opções metodológicas

Objetivo específico	Abordagem	Natureza	Dados coletados	Público-alvo	Amostragem	Técnicas de coleta	Técnicas de análise	Apresentação
Sistematizar literatura sobre avaliação de RAG	Qualitativa	Exploratória	Artigos, relatórios, diretrizes e benchmarks	Pesquisadores e gestores públicos	Intencional por pertinência temática	Pesquisa bibliográfica e documental	Síntese crítica por temas e lacunas	Texto e quadro-síntese
Selecionar técnicas de avaliação aplicáveis ao caso	Multimétodos	Exploratória	Métricas, rubricas, critérios e protocolos	Gestores, equipes técnicas e avaliadores	Seleção por adequação ao problema	Fichamento e análise de protocolos	Comparação metodológica e análise de viabilidade	Protocolo de avaliação
Caracterizar o acervo legislativo	Qualitativa	Descritiva	Discursos, metadados e documentação do corpus	Usuários de informação legislativa	Corpus da 56 ^a Legislatura	Pesquisa documental e registro de versões	Caracterização documental e análise de metadados	Descrição do corpus
Construir bateria e gold standard	Multimétodos	Exploratória	Perguntas, respostas esperadas e evidências	Avaliadores e pesquisadores	Amostra balanceada por tipo de pergunta	Curadoria, anotação e piloto	Categorização, adjudicação e validação	Bateria e quadro de evidências
Avaliar recuperação documental	Quantitativa	Descritiva	Trechos recuperados e evidências esperadas	Equipes técnicas e pesquisadores	Perguntas da bateria	Execuções controladas e baselines	Hit@k, Recall@k, Precision@k, MRR e nDCG	Tabelas e gráficos
Avaliar geração e julgamentos	Multimétodos	Descritiva	Respostas, notas humanas e notas de LLM como juiz	Avaliadores humanos e gestores	Amostra de respostas por categoria	Rubrica humana, piloto e LLM como juiz	Estatísticas, concordância e análise de erros	Tabelas, exemplos e discussão
Analisar condições de governança	Qualitativa	Descritiva	Resultados, erros e literatura normativa	Gestores públicos e equipes de governança	Casos críticos e achados do protocolo	Análise documental e síntese dos resultados	Análise temática e recomendações	Recomendações institucionais

Fonte: elaborado pelo autor.

5. CRONOGRAMA DA PESQUISA

A seguir apresenta-se a estimativa preliminar das atividades de pesquisa e de seus respectivos prazos. O cronograma toma maio de 2026 como mês inicial e deverá ser ajustado conforme o calendário oficial do programa, a definição de orientação, a qualificação e a disponibilidade de avaliadores humanos.

Tabela 2: Descritivo preliminar de atividades e prazos de entrega

	mai/26	jun/26	jul/26	ago/26	set/26	out/26	nov/26	dez/26	jan/27	fev/27
Atividades de pesquisa										
Início da orientação e refinamento do problema	X	X								
Revisão de literatura e matriz teórica	X	X	X							
Definição do protocolo de avaliação		X	X							
Coleta, tratamento e organização do corpus		X	X	X						
Construção da bateria de perguntas e gold standard			X	X						
Exame de qualificação				X						
Execução do sistema RAG, baselines e variações controladas				X	X					
Avaliação humana e avaliação por LLM como juiz					X	X				
Análise dos dados e interpretação dos resultados						X	X			
Compilação dos resultados e recomendações							X	X		
Redação e revisão dos capítulos da dissertação						X	X	X		
Depósito da versão final da dissertação									X	
Previsão de defesa da dissertação									X	
Elaboração de artigo científico derivado									X	X

Fonte: elaborado pelo autor (2026).

6. REFERÊNCIAS

- ALMEIDA, Patricia Gomes Rêgo de; SANTOS JÚNIOR, Carlos Denner dos. Artificial intelligence governance: Understanding how public organizations implement it. **Government Information Quarterly**, v. 42, n. 1, p. 102003, 2025. DOI: [10.1016/j.giq.2024.102003](https://doi.org/10.1016/j.giq.2024.102003). Disponível em: [10.1016/j.giq.2024.102003](https://www.sciencedirect.com/science/article/pii/S0740624X24000959). Acesso em: 21 abr. 2026.
- ANH-HOANG, Dang; TRAN, Vu; NGUYEN, Le-Minh. Survey and Analysis of Hallucinations in Large Language Models: Attribution to Prompting Strategies or Model Behavior. **Frontiers in Artificial Intelligence**, v. 8, 2025. DOI: [10.3389/frai.2025.1622292](https://doi.org/10.3389/frai.2025.1622292). Disponível em: [10.3389/frai.2025.1622292](https://www.frontiersin.org/articles/10.3389/frai.2025.1622292/full). Acesso em: 8 abr. 2026.
- BANDEIRA, Cristina Leston; BERNARDES, Cristiane Brum. Information vs Engagement in Parliamentary Websites – A Case Study of Brazil and the UK. **Revista de Sociologia e Política**, v. 24, n. 59, p. 91–107, 2016. DOI: [10.5380/rsocp.v24i59.48709](https://doi.org/10.5380/rsocp.v24i59.48709). Disponível em: [10.5380/rsocp.v24i59.48709](https://revistas.ufpr.br/rsp/article/view/48709). Acesso em: 9 abr. 2026.
- BLANCO, Pedro Duarte. **Letras graúdas, letras miúdas: leitura e complexidade textual dos discursos em Plenário 2007-2024**. Brasília, fev. 2026. (Texto para Discussão, 357). Disponível em: [10.5380/rsocp.v24i59.48709](https://www12.senado.leg.br/publicacoes/estudos-legislativos/tipos-de-estudos/textos-para-discussao/td357). Acesso em: 21 abr. 2026.
- _____. **Plenário, Palanque, Estúdio: Discursos no Plenário do Senado Federal entre 2007 e 2024**. Brasília, dez. 2025. (Texto para Discussão, 355). Disponível em: [10.5380/rsocp.v24i59.48709](https://www12.senado.leg.br/publicacoes/estudos-legislativos/tipos-de-estudos/textos-para-discussao/td355). Acesso em: 21 abr. 2026.
- CHOUHAN, Ashish; GERTZ, Michael. LexDrafter: Terminology Drafting for Legislative Documents Using Retrieval Augmented Generation. In: PROCEEDINGS of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). Torino, Italia: ELRA e ICCL, mai. 2024. P. 10448–10458. Disponível em: [10.5380/rsocp.v24i59.48709](https://aclanthology.org/2024.lrec-main.913/). Acesso em: 29 abr. 2026.
- COLOMBO, Andrea; BERNASCONI, Anna; BELLOMARINI, Luigi; GUIZO, Luigi; MICHELACCI, Claudio; CERI, Stefano. LegisSearch: navigating legislation with graphs and large language models. **Artificial Intelligence and Law**, 2025. DOI:

[10.1007/s10506-025-09482-6](https://doi.org/10.1007/s10506-025-09482-6). Disponível em:

<<https://link.springer.com/article/10.1007/s10506-025-09482-6>>. Acesso em: 29 abr. 2026.

CRESWELL, John W.; PLANO CLARK, Vicki L. **Designing and Conducting Mixed Methods Research**. 3. ed. Thousand Oaks: SAGE Publications, 2018.

DAHL, Matthew; MAGESH, Varun; SUZGUN, Mirac; HO, Daniel E. Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models. **Journal of Legal Analysis**, v. 16, n. 1, p. 64–93, 2024. DOI: [10.1093/jla/laae003](https://doi.org/10.1093/jla/laae003). Disponível em: <<https://academic.oup.com/jla/article/16/1/64/7699227>>. Acesso em: 29 abr. 2026.

ES, Shahul; JAMES, Jithin; ESPINOSA-ANKE, Luis; SCHOCKAERT, Steven. **Ragas: Automated Evaluation of Retrieval Augmented Generation**. 2023. DOI: [10.48550/arXiv.2309.15217](https://doi.org/10.48550/arXiv.2309.15217). arXiv: [2309.15217](https://arxiv.org/abs/2309.15217). Disponível em: <<https://arxiv.org/abs/2309.15217>>. Acesso em: 21 abr. 2026.

GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliu; BI, Yuxi; DAI, Yi; SUN, Jiawei; WANG, Meng; WANG, Haofen. **Retrieval-Augmented Generation for Large Language Models: A Survey**. 2023. arXiv: [2312.10997](https://arxiv.org/abs/2312.10997). Disponível em: <<https://arxiv.org/abs/2312.10997>>. Acesso em: 9 abr. 2026.

GAO, Yunfan; XIONG, Yun; WANG, Meng; WANG, Haofen. **Modular RAG: Transforming RAG Systems into LEGO-like Reconfigurable Frameworks**. 2024. arXiv: [2407.21059](https://arxiv.org/abs/2407.21059). Disponível em: <<https://arxiv.org/abs/2407.21059>>. Acesso em: 9 abr. 2026.

GARRISON, Kevin; FISHER, William M.; BERGE, Astrid I. **Talk to the NDAA: Evaluating Retrieval Augmented Generation (RAG) on Congressional Legislation using Large Language Models (LLM)**. Alexandria, Virginia, ago. 2024. Disponível em: <<https://www.ida.org/-/media/feature/publications/t/ta/talk-to-the-ndaa/3001199.ashx>>. Acesso em: 29 abr. 2026.

GEUNIS, Lotte. **Parliamentary Monitoring Organizations: Partners in Parliamentary Oversight**. International IDEA. 2023. Disponível em: <<https://www.idea.int/publications/catalogue/html/parliamentary-monitoring-organizations-partners-parliamentary>>. Acesso em: 8 abr. 2026.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 7. ed. São Paulo: Atlas, 2022.

GUPTA, Shailja; RANJAN, Rajesh; SINGH, Surya Narayan. **A Comprehensive Survey of Retrieval-Augmented Generation (RAG): Evolution, Current Landscape and Future Directions**. 2024. arXiv: [2410.12837](https://arxiv.org/abs/2410.12837). Disponível em: <<https://arxiv.org/abs/2410.12837>>. Acesso em: 8 abr. 2026.

HEVNER, Alan R.; MARCH, Salvatore T.; PARK, Jinsoo; RAM, Sudha. Design Science in Information Systems Research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004. DOI: [10.2307/25148625](https://doi.org/10.2307/25148625). Disponível em: <https://aisel.aisnet.org/misq/vol28/iss1/6/>. Acesso em: 29 abr. 2026.

INTER-PARLIAMENTARY UNION. **Use Cases for AI in Parliaments**. Geneva, 2024. Disponível em: <https://www.ipu.org/file/20635/download>. Acesso em: 8 abr. 2026.

KHALIQ, Mohammed Abdul; CHANG, Paul Yu-Chun; MA, Mingyang; PFLUGFELDER, Bernhard; MILETIĆ, Filip. RAGAR, Your Falsehood Radar: RAG-Augmented Reasoning for Political Fact-Checking Using Multimodal Large Language Models. In: PROCEEDINGS of the Seventh Fact Extraction and VERification Workshop (FEVER). Miami, Florida, USA: Association for Computational Linguistics, nov. 2024. P. 280–296. DOI: [10.18653/v1/2024.fever-1.29](https://doi.org/10.18653/v1/2024.fever-1.29). Disponível em: <https://aclanthology.org/2024.fever-1.29/>. Acesso em: 9 abr. 2026.

LAKATOS, Eva Maria; MARCONI, Marina de Andrade. **Fundamentos de metodologia científica**. 9. ed. São Paulo: Atlas, 2021.

LEWIS, Patrick; PEREZ, Ethan; PIKTUS, Aleksandra; PETRONI, Fabio; KARPUKHIN, Vladimir; GOYAL, Naman; KÜTTLER, Heinrich; LEWIS, Mike; YIH, Wen-tau; ROCKTÄSCHEL, Tim; RIEDEL, Sebastian; KIELA, Douwe. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: ADVANCES in Neural Information Processing Systems. Curran Associates, Inc., 2020. v. 33, p. 9459–9474. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>. Acesso em: 29 abr. 2026.

LIU, Shuliang; LI, Xinze; LIU, Zhenghao; YAN, Yukun; YANG, Cheng; ZENG, Zheni; LIU, Zhiyuan; SUN, Maosong; YU, Ge. Judge as A Judge: Improving the Evaluation of Retrieval-Augmented Generation through the Judge-Consistency of Large Language Models. In: FINDINGS of the Association for Computational Linguistics: ACL 2025. Vienna, Austria: Association for Computational Linguistics, 2025. P. 5788–5807. DOI: [10.18653/v1/2025.findings-acl.301](https://doi.org/10.18653/v1/2025.findings-acl.301). Disponível em: <https://aclanthology.org/2025.findings-acl.301/>. Acesso em: 14 abr. 2026.

LIU, Yang; ITER, Dan; XU, Yichong; WANG, Shuohang; XU, Ruochen; ZHU, Chenguang. G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. In: PROCEEDINGS of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023. P. 2511–2522. DOI: [10.18653/v1/2023.emnlp-main.153](https://doi.org/10.18653/v1/2023.emnlp-main.153). Disponível em: <https://aclanthology.org/2023.emnlp-main.153/>. Acesso em: 14 abr. 2026.

- MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. **Introduction to Information Retrieval**. Cambridge: Cambridge University Press, 2008. Disponível em: <<https://nlp.stanford.edu/IR-book/>>. Acesso em: 18 mai. 2026.
- MARTELLOTE VIOLA, Carla Maria; MARQUES FELIPE, Carla Beatriz; FARIAS SALES MARQUES, Luana. Inteligência Artificial na Organização do Conhecimento do Parlamento brasileiro: um estudo aplicado aos dados e às informações legislativas. **ISKO Brasil**, n. 8, 2025. Disponível em: <<https://isko.org.br/ojs/index.php/iskobrasil/article/view/52>>. Acesso em: 9 abr. 2026.
- MATOSHI, Veton; SINGH, Siddhartha; KUCERA, Jacqueline; MEYER, Philippe; GYGLI, Marcel. Transforming Digital Access in Parliament: Topic Modeling Meets Retrieval Augmented Generation. In: 2025 Eleventh International Conference on eDemocracy & eGovernment (ICEDEG). 2025. P. 123–130. DOI: [10.1109/ICEDEG65568.2025.11081627](https://doi.org/10.1109/ICEDEG65568.2025.11081627). Disponível em: <<https://doi.org/10.1109/ICEDEG65568.2025.11081627>>. Acesso em: 29 abr. 2026.
- MINAEE, Shervin; MIKOLOV, Tomas; NIKZAD, Narjes; CHENAGHLU, Meysam; SOCHER, Richard; AMATRIAIN, Xavier; GAO, Jianfeng. **Large Language Models: A Survey**. 2024. arXiv: [2402.06196](https://arxiv.org/abs/2402.06196). Disponível em: <<https://arxiv.org/abs/2402.06196>>. Acesso em: 8 abr. 2026.
- MOSBACH, Sebastian; LAI, Jiawei; RUSTAGI, Kushagar; TRAN, Dan N.; KRAFT, Markus; BINDEREIF, Ewald; AZZAM, Mark. **Parliamentary debates in The World Avatar: A hybrid retrieval-augmented generation system**. Set. 2025. Disponível em: <<https://como.ceb.cam.ac.uk/media/preprints/c4e-preprint-338.pdf>>. Acesso em: 29 abr. 2026.
- NIE, Zhijie; FENG, Zhangchi; LI, Mingxin; ZHANG, Cunwang; ZHANG, Yanzhao; LONG, Dingkun; ZHANG, Richong. **When Text Embedding Meets Large Language Model: A Comprehensive Survey**. 2024. arXiv: [2412.09165](https://arxiv.org/abs/2412.09165). Disponível em: <<https://arxiv.org/abs/2412.09165>>. Acesso em: 8 abr. 2026.
- PEFFERS, Ken; TUUNANEN, Tuure; ROTHENBERGER, Marcus A.; CHATTERJEE, Samir. A Design Science Research Methodology for Information Systems Research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45–77, 2007. DOI: [10.2753/MIS0742-1222240302](https://doi.org/10.2753/MIS0742-1222240302). Disponível em: <<https://doi.org/10.2753/MIS0742-1222240302>>. Acesso em: 29 abr. 2026.

PIPITONE, Nicholas; HOUIR ALAMI, Ghita. **LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain**. 2024. DOI: [10.48550/arXiv.2408.10343](https://arxiv.org/abs/2408.10343). arXiv: [2408.10343](https://arxiv.org/abs/2408.10343). Disponível em: [〈https://arxiv.org/abs/2408.10343〉](https://arxiv.org/abs/2408.10343). Acesso em: 29 abr. 2026.

ROGIERS, Alexander; BUYL, Maarten; KANG, Bram; DE BIE, Tijl. KamerRaad: Enhancing Information Retrieval in Belgian National Politics Through Hierarchical Summarization and Conversational Interfaces. In: MACHINE Learning and Knowledge Discovery in Databases. Research Track and Demo Track (ECML PKDD 2024). Cham: Springer, 2024. v. 14948. (Lecture Notes in Computer Science), p. 503–519. DOI: [10.1007/978-3-031-70371-3_30](https://arxiv.org/abs/2404.17597). Disponível em: [〈https://arxiv.org/abs/2404.17597〉](https://arxiv.org/abs/2404.17597). Acesso em: 29 abr. 2026.

SAAD-FALCON, Jon; KHATTAB, Omar; POTTS, Christopher; ZAHARIA, Matei. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. In: PROCEEDINGS of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Mexico City, Mexico: Association for Computational Linguistics, 2024. P. 338–354. DOI: [10.18653/v1/2024.naacl-long.20](https://aclanthology.org/2024.naacl-long.20). Disponível em: [〈https://aclanthology.org/2024.naacl-long.20/〉](https://aclanthology.org/2024.naacl-long.20/). Acesso em: 21 abr. 2026.

SKUBIC, Jure; FIŠER, Darja. Parliamentary Discourse Research in Political Science: Literature Review. In: PROCEEDINGS of the IV Workshop on Creating, Analysing, and Increasing Accessibility of Parliamentary Corpora (ParlaCLARIN) @ LREC-COLING 2024. Torino, Italia: ELRA e ICCL, mai. 2024. P. 1–11. Disponível em: [〈https://aclanthology.org/2024.parlaclarin-1.1/〉](https://aclanthology.org/2024.parlaclarin-1.1/). Acesso em: 8 abr. 2026.

THAKUR, Nandan; REIMERS, Nils; RÜCKLÉ, Andreas; SRIVASTAVA, Abhishek; GUREVYCH, Iryna. BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. In: PROCEEDINGS of the Neural Information Processing Systems Track on Datasets and Benchmarks. 2021. v. 1. Disponível em: [〈https://openreview.net/forum?id=wCu6T5xFjeJ〉](https://openreview.net/forum?id=wCu6T5xFjeJ). Acesso em: 18 mai. 2026.

VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES, Llion; GOMEZ, Aidan N.; KAISER, Lukasz; POLOSUKHIN, Illia. **Attention Is All You Need**. 2017. arXiv: [1706.03762](https://arxiv.org/abs/1706.03762). Disponível em: [〈https://arxiv.org/abs/1706.03762〉](https://arxiv.org/abs/1706.03762). Acesso em: 8 abr. 2026.

WESTMINSTER FOUNDATION FOR DEMOCRACY. **Guidelines for AI in Parliaments**. London, 2023. Disponível em: [〈https://www.agora-parl.org/sites/default/files/agora-documents/English%20-%20WFD%20AI%20Guidelines%20for%20Parliaments.pdf〉](https://www.agora-parl.org/sites/default/files/agora-documents/English%20-%20WFD%20AI%20Guidelines%20for%20Parliaments.pdf). Acesso em: 8 abr. 2026.

ZHU, Kunlun; LUO, Yifan; XU, Dingling; YAN, Yukun; LIU, Zhenghao; YU, Shi; WANG, Ruobing; WANG, Shuo; LI, Yishan; ZHANG, Nan; HAN, Xu; LIU, Zhiyuan; SUN, Maosong. RAGEval: Scenario Specific RAG Evaluation Dataset Generation Framework. In: PROCEEDINGS of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025. P. 8520–8544. DOI: [10.18653/v1/2025.acl-long.418](https://doi.org/10.18653/v1/2025.acl-long.418). Disponível em: <https://aclanthology.org/2025.acl-long.418/>. Acesso em: 14 abr. 2026.